Aprendizagem 2025/26
Homework II - Group 006

I. Pen-and-paper [13v]

1) Considerando que $x_1 - x_6$ são observações de treino, $x_7 - x_8$ são observações de teste e $y_1 - y_5$ são variáveis de input:

a)

	y_1	y_2	y_3	y_4	y_5	y_6
x_1	0.52	0.80	0	1	1	N
x_2	0.53	0.92	0	0	0	N
x_3	0.42	0.48	0	1	1	N
x_4	0.49	0.58	1	0	1	P
x_5	0.62	0.31	0	0	1	P
x_6	0.44	0.38	0	0	1	P

$Priori$:

$$P(y_6 = N) = P(y_6 = P) = \frac{1}{2}$$

$\{y_1, y_2\}$:
Vamos calcular primeiro:

$$\mu_N = \begin{bmatrix} \frac{0.52 + 0.53 + 0.42}{3} \\ \frac{0.8 + 0.92 + 0.48}{3} \end{bmatrix} = \begin{bmatrix} 0.49 \\ 0.7333 \end{bmatrix}$$

$$\sigma_{1N}^2 = \frac{1}{2}[(0.52 - 0.49)^2 + (0.53 - 0.49)^2 + (0.42 - 0.49)^2] = 0.0037$$

$$\sigma_{2N}^2 = \frac{1}{2}[(0.80 - 0.7333)^2 + (0.92 - 0.7333)^2 + (0.48 - 0.7333)^2] = 0.051733$$

$$cov(y1, y2) = cov(y2, y1)$$
$$cov(y1, y2)_N = \frac{1}{2}[(0.03)(0.0667) + (0.04)(0.1867) + (-0.07)(-0.2533)] = 0.0136$$

$$\Sigma_{1,2\,N} = \begin{bmatrix} 0.0037 & 0.0136 \\ 0.0136 & 0.051733 \end{bmatrix}$$

$$\mu_P = \begin{bmatrix} \frac{0.49 + 0.62 + 0.44}{3} \\ \frac{0.58 + 0.31 + 0.38}{3} \end{bmatrix} = \begin{bmatrix} 0.517 \\ 0.423 \end{bmatrix}$$

$$\sigma_{1P}^2 = \frac{1}{2}[(0.49 - 0.517)^2 + (0.62 - 0.517)^2 + (0.44 - 0.517)^2] = 0.008634$$

$$\sigma_{2P}^2 = \frac{1}{2}[(0.58 - 0.423)^2 + (0.31 - 0.423)^2 + (0.38 - 0.423)^2] = 0.0196335$$

$$cov(y1, y2) = cov(y2, y1)$$
$$cov(y1, y2)_N = \frac{1}{2}[(-0.026)(0.157) + (0.104)(-0.113) + (-0.076)(-0.043)] = -0.006283$$

$$\Sigma_{1,2\,P} = \begin{bmatrix} 0.008634 & -0.006283 \\ -0.006283 & 0.0196335 \end{bmatrix}$$

Como y_1 X $y_2 \sim N(\mu, \sigma^2)$:

$$P(y_1, y_2|\mu, \sigma^2) = \frac{1}{2\pi\sqrt{|\Sigma|}} e^{(-\frac{1}{2}[y-\mu]^T \Sigma^{-1}[y-\mu])}$$

$$\Sigma^{-1} = \frac{1}{det(\Sigma)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

$$det(\Sigma_{1,2\,N}) = 0.0037 \times 0.051733 - (0.0136)^2 = 0.0000064521$$

$$\Sigma^{-1}{}_{1,2\,N} = \frac{1}{0.0000064521} \begin{bmatrix} 0.051733 & -0.0136 \\ -0.0136 & 0.0037 \end{bmatrix} = \begin{bmatrix} 8018.01 & -2107.84 \\ -2107.84 & 573.457 \end{bmatrix}$$

$$det(\Sigma_{1,2\,P}) = 0.008634 \times 0.0196335 - (0.006283)^2 = 0.00013004$$

$$\Sigma^{-1}{}_{1,2\,P} = \frac{1}{0.00013004} \begin{bmatrix} 0.0196335 & 0.006283 \\ 0.006283 & 0.008634 \end{bmatrix} = \begin{bmatrix} 150.98 & 48.316 \\ 48.316 & 66.395 \end{bmatrix}$$

Portanto,

$$P(y_1, y_2|\mu_N, \sigma_N^2) = \frac{1}{2\pi\sqrt{0.0000064521}} e^{(-\frac{1}{2}[y-\mu_N]^T \Sigma^{-1}{}_N [y-\mu_N])}$$

$$P(y_1, y_2|\mu_P, \sigma_P^2) = \frac{1}{2\pi\sqrt{0.00013004}} e^{(-\frac{1}{2}[y-\mu_P]^T \Sigma^{-1}{}_P [y-\mu_P])}$$

$\{y_3, y_4\}$:
$P(y_3 = 0, y_4 = 0 \mid y_6 = N) = \frac{1}{3}$
$P(y_3 = 0, y_4 = 0 \mid y_6 = P) = \frac{2}{3}$

$P(y_3 = 1, y_4 = 0 \mid y_6 = N) = 0$
$P(y_3 = 1, y_4 = 0 \mid y_6 = P) = \frac{1}{3}$

$P(y_3 = 0, y_4 = 1 \mid y_6 = N) = \frac{2}{3}$
$P(y_3 = 0, y_4 = 1 \mid y_6 = P) = 0$

$\{y_5\}$:
$P(y_5 = 0 \mid y_6 = N) = \frac{1}{3}$
$P(y_5 = 0 \mid y_6 = P) = 0$

$P(y_5 = 1 \mid y_6 = N) = \frac{2}{3}$
$P(y_5 = 1 \mid y_6 = P) = 1$

Apesar da fórmula para calcular os $posteriors$ ser dada por:

$$P(h|x) = \frac{P(x|h)P(h)}{P(x)}$$

Consideramos que $P(x)$ é uma constante, não influenciando o valor relativo dos posteriors.

Os $posteriors$ são dados por:

$P(N|x) \propto P(y_1, y_2 \mid N)\, P(y_3, y_4 \mid N)\, P(y_5 \mid N)\, P(N)$

$P(P|x) \propto P(y_1, y_2 \mid P)\, P(y_3, y_4 \mid P)\, P(y_5 \mid P)\, P(P)$

b)

$x_7 = (0.45, 0.80, 0, 0, 1)$
$P(N \mid 0.45, 0.80, 0, 0, 1) = P(y_1 = 0.45, y_2 = 0.80 \mid N)\, P(y_3 = 0, y_4 = 0 \mid N)\, P(y_5 = 1 \mid N)$

Primeiramente:

$$P(y_1 = 0.45, y_2 = 0.80 \mid N) = \frac{1}{2\pi\sqrt{0.0000064521}} e^{(-\frac{1}{2}[y-\mu_N]^T \Sigma^{-1}{}_N [y-\mu_N])} =$$

$$\frac{1}{2\pi \times 0.0025} e^{\left(-\frac{1}{2}[-0.04 \quad 0.0667]\begin{bmatrix} 8018.01 & -2107.84 \\ -2107.84 & 573.457 \end{bmatrix}\begin{bmatrix} -0.04 \\ 0.0667 \end{bmatrix}\right)} =$$

$$\frac{1}{2\pi \times 0.0025} e^{\left(-\frac{1}{2} \times 26.6274974\right)} \approx 0.000105$$

$$P(N \mid 0.45, 0.80, 0, 0, 1) = 0.000105 \times \frac{1}{3} \times \frac{2}{3} \times \frac{1}{2} \approx 0.000012$$

$$P(P \mid 0.45, 0.80, 0, 0, 1) = P(y_1 = 0.45, y_2 = 0.80 \mid P)\, P(y_3 = 0, y_4 = 0 \mid P)\, P(y_5 = 1 \mid P)$$

Primeiramente:

$$P(y_1 = 0.45, y_2 = 0.80 \mid P) = \frac{1}{2\pi\sqrt{0.00013004}} e^{(-\frac{1}{2}[y-\mu_P]^T \Sigma^{-1}{}_P \, [y-\mu_P])} =$$

$$\frac{1}{2\pi \times 0.0114} e^{\left(-\frac{1}{2}[-0.066 \quad 0.377]\begin{bmatrix} 150.98 & 48.316 \\ 48.316 & 66.395 \end{bmatrix}\begin{bmatrix} -0.066 \\ 0.377 \end{bmatrix}\right)} =$$

$$\frac{1}{2\pi \times 0.0114} e^{\left(-\frac{1}{2} \times 7.6899264\right)} \approx 0.298586$$

$$P(P \mid 0.45, 0.80, 0, 0, 1) = 0.298586 \times \frac{2}{3} \times 1 \times \frac{2}{3} \approx 0.1327$$

De acordo com o que é pedido no enunciado, $Maximum\ a\ posterior\ (MAP)$:
Conclui-se que x_7 pertence à classe P porque $P(P \mid 0.45, 0.80, 0, 0, 1) > P(N \mid 0.45, 0.80, 0, 0, 1)$

$x_8 = (0.50, 0.70, 0, 1, 1)$

$$P(N \mid 0.50, 0.70, 0, 1, 1) = P(y_1 = 0.50, y_2 = 0.70 \mid N)\, P(y_3 = 0, y_4 = 1 \mid N)\, P(y_5 = 1 \mid N)$$

Primeiramente:

$$P(y_1 = 0.50, y_2 = 0.70 \mid N) = \frac{1}{2\pi\sqrt{0.0000064521}} e^{(-\frac{1}{2}[y-\mu_N]^T \Sigma^{-1}{}_N [y-\mu_N])} =$$

$$\frac{1}{2\pi \times 0.0025} e^{\left(-\frac{1}{2}[0.01 \quad -0.0333]\begin{bmatrix} 8018.01 & -2107.84 \\ -2107.84 & 573.457 \end{bmatrix}\begin{bmatrix} 0.01 \\ -0.0333 \end{bmatrix}\right)} =$$

$$\frac{1}{2\pi \times 0.0025} e^{\left(-\frac{1}{2} \times 2.8415232\right)} \approx 15.376277$$

$$P(N \mid 0.50, 0.70, 0,1,1) = 15.376277 \times \frac{2}{3} \times \frac{2}{3} \times \frac{1}{2} = 3.4169$$

$$P(P \mid 0.50, 0.70, 0,1,1) = P(y_1 = 0.50, y_2 = 0.70 \mid P)\, P(y_3 = 0, y_4 = 1 \mid P)\, P(y_5 = 1 \mid P)$$

Sabemos que $P(y_3 = 0, y_4 = 1 \mid P) = 0$ portanto é desnecessário fazer os restantes cálculos.
Conclui-se que x_8 pertence à classe N porque $P(N \mid 0.50, 0.70, 0,1,1) > P(P \mid 0.50, 0.70, 0,1,1)$.

2) Considerando que $y_3 - y_5$ são variáveis de input.

Vamos calcular a distância Hamming com o esquema de $leave - one - out$:

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_1	–	2	**0**	2	1	1	1	**0**

$2kNN: x_3, x_8$ $\hat{Z}_1: moda(N, N) = N$ $Z_1: N \rightarrow TP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_2	2	–	2	2	1	1	1	2

$3kNN: x_5, x_6, x_7$ $\hat{Z}_2: moda(P, P, P) = P$ $Z_2: N \rightarrow FP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_3	0	2	–	2	1	1	1	0

$2kNN: x_1, x_8$ $\hat{Z}_3: moda(N, N) = N$ $Z_3: N \rightarrow TN$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_4	2	2	2	–	1	1	1	2

$3kNN: x_5, x_6, x_7$ $\hat{Z}_4: moda(P, P, P) = P$ $Z_4: P \rightarrow TP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_5	1	1	1	1	–	0	0	1

$2kNN: x_6, x_7$ $\hat{Z}_5: moda(P,P) = P$ $Z_5: P \rightarrow TP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_6	1	1	1	1	0	–	0	1

$2kNN: x_5, x_7$ $\hat{Z}_6: moda(P,P) = P$ $Z_6: P \rightarrow TP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_7	1	1	1	1	0	0	–	1

$2kNN: x_5, x_6$ $\hat{Z}_7: moda(P,P) = P$ $Z_7: P \rightarrow TP$

H	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_8	0	2	0	2	1	1	1	–

$2kNN: x_1, x_3$ $\hat{Z}_8: moda(N,N) = N$ $Z_2: P \rightarrow TN$

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{4+3}{8} \approx 0.875$$

3)

a) $posterior$:

$P(\Theta = i | X = x) \propto P(\Theta = i) P(X = x | \Theta = i)$

Como $P(X = x | \Theta = 1) = P(X = x | \Theta = 0)$, podemos comparar apenas $P(\Theta = 1)$ com $P(\Theta = 0)$.

Como $P(\Theta = 0) = p$ e $p \geq \frac{1}{2}$,
então $P(\Theta = 0) \geq P(\Theta = 1)$,
logo $P(\Theta = 0 | X = x) \geq P(\Theta = 1 | X = x)$.

Portanto o classificador escolhe sempre a classe 0 porque estamos a utilizar a abordagem $Maximum\ a\ posterior\ (MAP)$, na qual, escolhemos a classe que maximiza o $posterior$

$$E_{Bayes} = P(\Theta \neq \Theta_{Bayes}) = P(\Theta \neq 0) = P(\Theta = 1) = 1 - P(\Theta = 0) = 1 - p$$

b) $P(\Theta = 0 | X = x) = \frac{P(X=x \mid \Theta=0)\, P(\Theta=0)}{P(X=x)} = \frac{P(X=x \mid \Theta=0)\, P(\Theta=0)}{P(X=x \mid \Theta=0)\, P(\Theta=0) + P(X=x \mid \Theta=1)\, P(\Theta=1)} = \frac{P(\Theta=0)}{P(\Theta=0)+P(\Theta=1)} = \frac{p}{p+1-p} = = \frac{p}{1} = p$

$P(\Theta = 1 | X = x) = \ldots = 1 - p$

$2 \times P(\Theta = 0 | X = x) \times P(\Theta = 0 | X = x) = 2 \times p \times (1 - p) = 2p(1 - p)$

c) $E_{1NN} = 2p(1 - p)$

$E_{Bayes} = 1 - p$

$2p(1 - p) = 2\ X\ (1 - p)\ X\ (1 - 1 + p) = 2p(1 - p) = 2\ X\ p\ X\ (1 - p)\ cqd$

II. Programming and critical analysis [7v]

1. O shuffle = true faz com que a criação de folds seja após misturar o dataset o que evita que uma ordem original possa causar folds não representativos. No entanto, sempre que usamos o shuffle há um elemento de aleatoriedade, ou seja, cada execução causa folds diferentes. Neste sentido decidimos usar o parâmetro random_state (neste caso a 0) para controlarmos essa aleatoriedade e obter resultados consistentes.

a) Os dados que obtivemos foram os seguintes:

```
Acurácia kNN: [0.99270073 0.96350365 0.96350365 0.94117647
0.98529412]
Acurácia Naive Bayes: [0.98540146 0.94890511 0.94890511
0.95588235 0.97058824]
```

Podemos observar que o kNN tem uma acurácia mais elevada em todos os folds, no entanto, como isto não chega para determinar se é ou não mais estável do que o naive bayes decidimos calcular também as médias e os desvios padrão dos dois modelos. E obtivemos os seguintes dados:

```
Desvio padrão kNN: 0.018229172031416895
Média kNN: 0.9692357234864749

Desvio padrão naive bayes: 0.014154461052591927
Média naive bayes: 0.9619364534134822
```

Concluímos que kNN apresenta um desvio padrão superior ao de Naiive Bayes mesmo tendo uma média de acurácia ligeiramente maior, o que indica que o kNN é o menos estável. Neste sentido, o modelo mais estável seria o Naive Bayes.
Esta conclusão pode ser explicada pelas diferenças fundamentais entre os dois modelos. Para começar o Naive Bayes é um classificador probabilístico paramétrico que assume independência condicional entre as variáveis. Por este motivo tende a ter uma baixa variação quando mudamos a amostra de treino, sendo consideravelmente estável. Já o kNN depende diretamente dos vizinhos, portanto é mais sensível a pequenas mudanças nos folds e ao ruído.

b)
```
Accuracy kNN with preprocessing the data with a Min-Max scaler:
[0.99270073 0.96350365 0.96350365 0.94117647 0.97794118]
Desvio Padrão: 0.017138338919556715
Média: 0.9677651352511807
```

O Min-Max Scaler é uma técnica de normalização de variáveis que transforma linearmente os dados para um intervalo fixo, neste caso entre 0 e 1. O kNN decide com base nas distâncias entre os pontos, por defeito a distância euclidiana. Se algumas features tiverem valores muito superiores às restantes, estas acabam por dominar a distâncias e as outras ficam irrelevantes. Escalar as features para o mesmo intervalo ([0,1]) faz com que todas contribuam de forma comparável para a distância e as decisões passem a utilizar informação mais completa o que pode melhorar a acurácia da kNN.
No nosso caso, todas as variáveis são categóricas e já estão na mesma escala ([0,10]). Portanto, o Min-Max Scaler torna-se praticamente irrelevante e pode até ser ligeiramente prejudicial, pois aproxima todas as variáveis e comprime o espaço de representação. Na prática, isso confirma-se, pois a média da acurácia do modelo foi levemente inferior após a normalização (queda de 0.00147), um valor negligenciável, mas não deixa de ser inferior.

c) Para determinar se o kNN escalado é estatisticamente superior ao Naive Bayes decidimos usar o t-test, assim podemos comparar os dois resultados e analisar se há uma diferença estatística significativa.

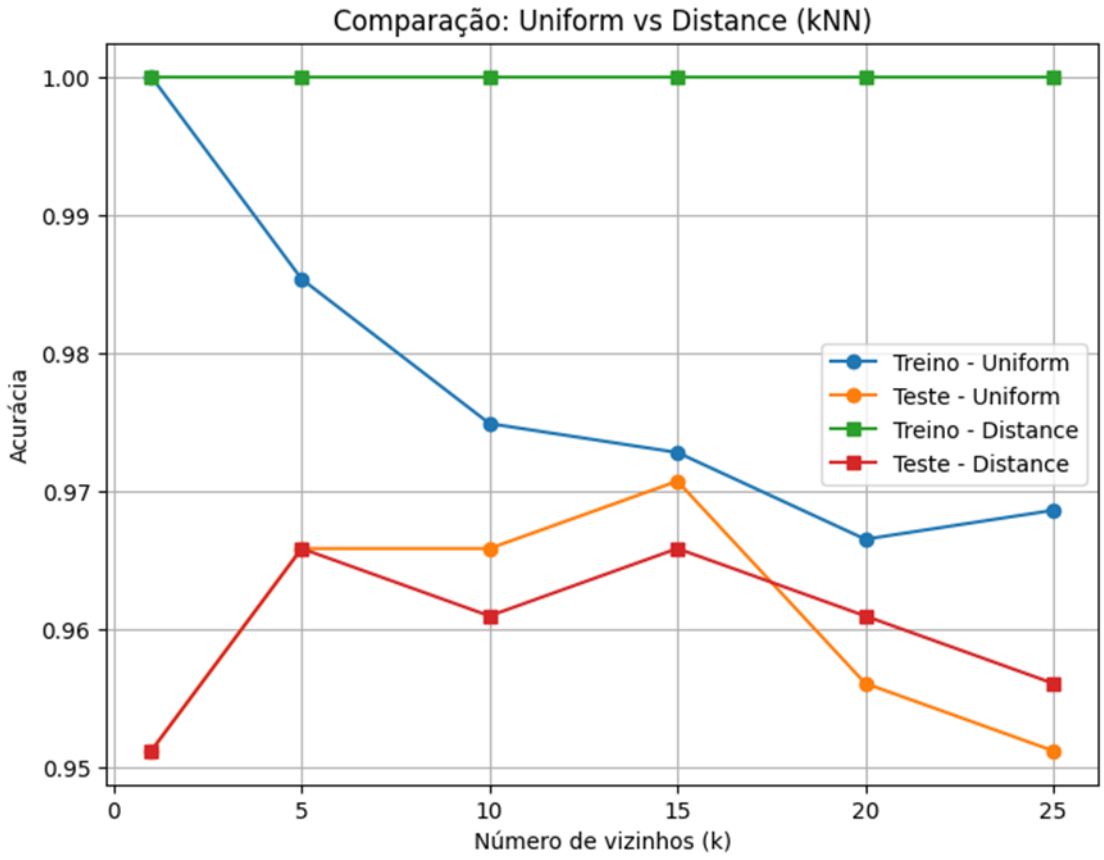
Dados recolhidos:

```
Acurácias kNN escalado: [0.99270073 0.96350365 0.96350365
0.94117647 0.97794118]
Acurácias Naive Bayes escalado: [0.98540146 0.94890511
0.94890511 0.95588235 0.97058824]
Teste t-> t: 1.0823822303350672 p: 0.3399717747301736
Média kNN: 0.9677651352511807
Média NB: 0.9619364534134822
Conclusão: não há diferença estatisticamente significativa entre
os modelos.
```

Como p>0.05 , não é possível afirmar que haja uma diferença estatisticamente significativa entre os modelos, pelo menos quando comparamos a acurácia.

2.

a)



b) Quando o valor de k é pequeno (por exemplo, k=1) o classificador é sensível e flexível às variações do conjunto de treino. Neste caso, o modelo tende a memorizar os dados do conjunto de treino, obtendo uma acurácia de treino de 100%, mas uma acurácia do conjunto de teste inferior (95.1%) caracterizando um claro overfitting. Nestes valores de k o modelo ajusta-se demasiado aos dados de treino e não consegue generalizar de forma eficaz.

   À medida que k aumenta para valores intermédios (entre K=5 e K=15) o classificador considera um número maior de vizinhos na sua decisão, o que suaviza as fronteiras de decisão reduzindo a influência de possíveis outliers. Isto melhora a capacidade de generalização, captando melhor as tendências dos dados de teste. Nos resultados obtidos, observou-se que a acurácia de teste atinge o seu máximo (97%) para K =15 com pesos uniformes, indicando o melhor ponto de equilíbrio. No caso dos pesos distance, as variações foram menores e a acurácia, apesar de máxima, ligeiramente inferior (96,5%) o que demonstra um comportamento mais estável.

   Quando K assume valores muito elevados (k>15) o modelo passa a considerar vizinhos demasiado distantes e, muitas vezes, de classes diferentes, o que leva a uma redução da acurácia de teste e que caracteriza underfitting.

   Com base nestes dados, conclui-se que o valor ótimo de K é 15 com pesos uniformes, pois apresenta a melhor acurácia de teste e uma boa proximidade entre os dois conjuntos. Os pesos uniformes proporcionam menos overfitting, enquanto os pesos distance são mais agressivos e tendem a manter o treino perfeito, com risco ligeiramente maior de overfitting.

3. Na escolha entre kNN e Naive Bayes para diagnóstico de cancro da mama, vários fatores devem ser considerados. O Naive Bayes assume que todas as variáveis são independentes, o que raramente acontece e é irrealista, principalmente em dados médicos, dado que atributos como Clump Thickness, Cell Size Uniformity e Cell Shape Uniformity estão correlacionados na prática, e havendo muita correlação entre os atributos, a performance do modelo pode ser comprometida. Por outro lado, kNN não faz suposições de independência e consegue capturar de uma melhor maneira relações complexas entre diferentes características, o que melhora a capacidade de generalização de variáveis dependentes.

   Naive Bayes é mais interpretável, permitindo aos médicos entender a contribuição de cada atributo para o risco de cancro e como estão relacionados, enquanto que o kNN é menos transparente pois a decisão depende das distâncias tornando muito mais difícil justificar classificações dos pacientes.

O kNN exige os cálculos das distâncias entre cada nova amostra e todo o conjunto de treino, o que pode ser computacionalmente muito intensivo, especialmente em grandes bases de dados como é o caso dos dados médicos dos pacientes. O naive bayes, por sua vez, é rápido de treinar e prever.

Com base nos nossos dados, Naive Bayes mostrou-se mais estável a variações no dataset e eficiente mas menos credível devido à suposição de independência entre variáveis. O kNN atingiu acurácias mais altas, inclusive a sua média foi superior, mas com maior custo e menos interpretabilidade, apesar de não assumir independência entre atributos.

Para um sistema que prioriza máxima acurácia e que dispõe de capacidade computacional suficiente como é o caso dos hospitais com grandes bases de dados médicos, o kNN seria preferível. Apesar de ter menor interpretabilidade, fornece previsões mais precisas e reflete melhor a realidade dos dados clínicos. Naive Bayes seria mais útil como ferramenta de pesquisa, permitindo analisar como determinados sintomas contribuem para o risco de cancro de forma independente de outros atributos.